

迈向普适计算中的可信代理人工智能：首届关于动态评估、执行安全性与精度对齐的研讨会及挑战赛

赵健

中国人工智能研究院（TeleAI），中国电信西北 polytechnic 大学，北京，中国 zhaojian90@u.nus.edu

张天乐

中国人工智能研究院（TeleAI），中国电信北京，中国 zhangtianle95@gmail.com

摘要

人工智能代理正被部署在手机、可穿戴设备及其他无处不在的计算系统中。这些代理能够使用各类工具，在不同应用程序间协同运作，并根据实时上下文环境做出决策。在这类系统中，三个核心问题日益凸显：首先，代理必须具备抵御提示注入攻击和不安全工具操控等自适应攻击的能力；其次，安全性评估应基于执行过程中的表现，而不仅仅是最终输出结果；第三，即使已知某种故障模式，仍难以在不影响系统其他关键功能的前提下修复该行为。为此，我们特别策划了一场为期一天的研讨会及挑战赛，聚焦于无处不在计算领域中可信的代理式人工智能技术。本次研讨会围绕三个相互关联的主题展开：动态攻击、执行安全性以及精确对齐。活动内容包括短篇论文报告、海报展示、挑战赛参赛作品提交、特邀演讲以及讨论环节。

关键词

人工智能代理、普适计算、移动系统、人工智能安全

1 研讨会范围与目标

智能代理系统现已应用于手机、可穿戴设备及智能空间[17]。这些系统能够调用各类工具、跨应用程序协同操作，并根据不断变化的上下文响应用户请求。由于这类系统具备观察环境并采取行动的能力，其安全性取决于整个交互过程。我们不仅需要评估代理所说的内容，还需判断其所见信息、使用的工具、执行的操作，以及何时应停止运行或寻求帮助。

本次研讨会聚焦于适用于普适计算的可信代理式人工智能。研讨会围绕这些系统中出现的三个具体问题展开讨论：第一个问题是适应性攻击下的鲁棒性——使用工具的智能体可能通过提示、应用程序、网页内容或外部连接接收到不安全指令；第二个问题是执行安全性。即使最终任务看起来正确，交互过程中仍可能包含高风险操作、不安全的工具使用方式，或错失停止时机的机会。第三个问题是精准修复：当故障模式已明确时，现有的修复方案可能过于笼统，不仅会消除安全行为，还可能削弱系统应有的正常功能。

这三个问题构成了本次研讨会的设计框架。第一专题聚焦于针对移动设备、多模态及工具使用型智能体的动态攻击研究；第二专题探讨应用程序使用过程及环境交互中的执行安全性；第三专题研究能够以有限副作用修复不安全行为的精确对齐方法。举办本次研讨会的必要性在于这三个问题应当协同讨论。

在无处不在的系统中，它们是同一安全问题的不同组成部分。

UbiComp 系统具备情境感知能力、支持多设备运行且以操作为导向。这些系统的安全性不仅体现在生成的文本内容上，还涉及规划流程、权限管理、工具使用方式以及与数字及物理环境的交互关系。

时机的选择同样至关重要。智能体的能力正在迅速提升，而其无处不在的部署使得其故障带来的后果更为严重。移动或可穿戴代理能够影响信息传递、购买行为、导航操作、隐私保护以及对敏感情境的访问权限。这些正是普适计算的核心应用场景。近期关于 Android 代理、Web 代理安全、MCP 安全及视觉提示注入的研究既展现出快速进展，也暴露出明显的安全漏洞[1, 5, 11, 17, 19]。在此阶段举办专题研讨会，有助于在特定基准测试习惯固化之前完善评估实践方法。

2 主题与挑战赛道

我们诚邀提交关于普适计算与可穿戴计算领域中可信智能体行为的研究论文及挑战性投稿。主题包括：

- 针对使用工具、移动式、多模态及连接 MCP 的智能代理发起的攻击；
- 不当的即时注入操作、不安全的工具调用以及存在风险的应用间交互行为；
- 交互过程中的执行跟踪、流程检查及安全监控；
- 用于动态智能体评估的数据集、模拟器、日志文件及基准测试工具；
- 模型编辑、选择性遗忘及其他定向对齐方法；
- 手机、可穿戴设备及智能环境中的助手功能在安全性与实用性之间的权衡。

本次研讨会包含三项挑战任务。

轨道 1：特工与 MCP 的袭击。本研究方向致力于解决鲁棒性问题，重点探讨针对工具使用型智能体的自适应攻击。典型攻击类型包括提示注入、工具滥用、跨应用操控，以及通过外部工具或 MCP 连接实施的攻击。核心问题是：当攻击策略发生变化时，智能体是否仍能保持安全性[5, 6, 8–11, 18, 19]。

路径 2：执行安全性。该路径针对交互过程中的评估问题展开研究，旨在验证智能体在与手机、应用程序、网络服务或其他情境界面交互时是否采取安全行为。相关研究主题包括风险行为检测、状态感知干预、轨迹检查以及从异常情况中恢复等。

不安全计划。这一研究方向的动机在于：许多关键性失败现象并非仅出现在最终答案中，而是普遍存在于操作过程的追踪记录中[1, 17]。

轨道3：精确对齐。该轨道致力于解决修复问题，重点研究如何针对不安全智能体行为进行定向修复。相关研究主题包括模型编辑、概念移除，以及在保持周边良性行为不变的前提下提升安全性的方法[2、7、12、14]。

这三个研究方向紧密相连。第一项研究探讨故障是如何触发的；第二项研究探究故障在交互过程中如何显现；第三项研究则致力于以精确的方式修复这些故障。

我们采用挑战赛形式，因为这种方式能让这些关联更加具体化。纯论文形式固然仍有其价值，但在共享任务设计下，比较不同攻击场景、执行日志及修复方法会更为困难。挑战赛为研讨会提供了统一的讨论基础，同时也便于在同一问题的不同层面之间对比各种解决方案。

我们预计提交的材料将涵盖不同成熟度层次。部分报告可能涉及新的基准测试或模拟工具；部分研究可能展示移动设备或多模态智能体中风险行为的案例分析；还有研究可能聚焦于防御机制、修复方法或安全监控技术。这一广泛的研究范围对本次研讨会极具价值，因为该领域仍处于发展初期，有助于会议既展现技术深度，又能总结早期系统应用中的实践经验。

3 格式、参与方式及计划

我们拟举办一场为期一天、线下进行的开放式研讨会。UbiComp/ ISWC 2026研讨会将于2026年10月11日至12日在主会议之前举行，仅限线下参与，不限于已录用论文的作者。预计参会人数为30至45人，参与者可能包括UbiComp/ ISWC 的研究人员、从事智能体系统研究的学者，以及专注于可信人工智能、评估与验证领域的研究人员。

我们计划提供两种提交类型：

- 档案工作坊论文，2至4页；
- 非档案类参与声明或单页海报。

所有投稿将经过初步评审流程。我们将评估其相关性、表述清晰度、技术质量及讨论价值。预计可接受10至15篇投稿，其中部分优秀稿件将被选中进行简短的口头专题报告。其他获认可的研究成果将以海报形式展示。论文篇幅控制在较短范围内是经过刻意设计的，此举降低了新研究、早期基准测试结果、负面实验结果以及对这一快速发展的领域首次研讨会具有实用价值的系统观察报告的提交门槛。

本次研讨会采用以讨论为主的形式。我们不希望它演变成小型会议，而是严格遵循2026年UbiComp/ ISWC 大会标准的一日研讨会安排。初步日程安排如下：

- **08:30–08:45：**开幕：挑战目标与后勤安排（李雪龙博士）；
- **08:45–09:30：**主题演讲1（T1）：潘周博士（南卫理公会大学）——高效智能推理；
- **09:30–10:15：**第二场主题演讲（T2）：杨耀东博士（北京大学）——人工智能对齐与安全强化学习；

- **10:45–12:00：**挑战焦点一：赛道1和赛道2获胜者（口头陈述）；
- **12:00–13:30：**午餐休息时间；
- **13:30–14:15：**第三场主题演讲（T3）：Alessio R. Lomuscio 教授（帝国大学）
 - 安全AI验证；
- **14:15–15:00：**特邀演讲：景丽萍教授（BJTU）——鲁棒且可解释的智能体；
- **15:00–15:30：**咖啡休息时间及海报展示会B；
- **15:30–16:30：**挑战焦点II：赛道3获奖者介绍及技术问答环节；
- **16:30–17:00：**颁奖典礼及闭幕致辞。

我们还计划沿用提案早期版本中的特邀演讲嘉宾阵容，包括Alessio R. Lomuscio（英国帝国理工学院）、Pan Zhou（新加坡南洋理工大学）、Yaodong Yang（北京大学）和Liping Jing（BJTU）。该阵容在验证技术、对齐算法、推理方法及稳健智能体研究领域形成了均衡的组合。

若该提案于2026年5月2日获得批准，我们于2026年5月5日前公布研讨会官网及会议论文征集指南（CFP）。修订后的研讨会描述文件将确保在会议截止日期（2026年5月25日）前提交至《兼职会议录》及ACM数字图书馆。在5月至6月期间，我们将组建紧凑型项目委员会、发布征稿启事，并通过UbiComp/ ISWC 及相关学术社群进行研讨会宣传。暂定投稿截止时间为2026年6月下旬，通知发送时间为2026年7月中旬，最终稿件需于2026年7月31日前完成排版并提交。

我们还提议举办一场开放式研讨会，因为该主题涉及多个领域。部分参与者可能携带论文参会；另一些参与者则因开发智能体、移动系统或评估工具而希望参与讨论。开放格式将有助于该研讨会超越有限的已接受投稿范围，并使讨论对更广泛的UbiComp社区更具实用价值。

研讨会结束后，我们计划分享已审阅的材料（在允许的情况下提供幻灯片），并发布一份关于开放性问题及经验教训的简要公开总结。同时，我们还将把本次挑战赛的相关资源保留在线上，供后续使用。我们的目标不仅是举办一场为期一天的活动，更希望留下可重复使用的任务清单、更清晰的评估指标，以及为未来工作提供更完善的共同议程。

本次讨论环节将围绕与三个研究方向相契合的若干具体问题展开：在无处不在的智能代理系统中，何种行为可被视为有效的攻击成功案例？需要哪些日志或信号才能评估执行过程的安全性？对于必须在日常环境中保持实用性的智能代理而言，哪些修复方法具有足够的精确度？我们还将探讨如何在这些议题中构建一个能够平衡现实性、可重复性及风险覆盖范围的评估基准。

4 组织者及预期影响

该组织团队融合了在代理安全、基准测试、移动系统、隐私保护及部署领域的专业知识：

- **赵健**（TeleAI，中国电信；西北 Polytechnical University）：专注于可信人工智能、模型治理与安全评估

赵、张等人。

- **10:15—10:45:** 咖啡休息及海报展示会A;

领域。他负责协调研讨会及挑战赛的设计工作。

- **张天乐** (TeleAI, 中国电信): 专注于智能系统的鲁棒性、验证与评估研究。其专业背景为本次研讨会聚焦于可靠的评估方法与安全保障提供了有力支持。
- **周慧琳** (中国科学技术大学; TeleAI): 专注于多模态基础模型及扩散模型安全性研究。她在攻击方法竞赛的赛道设置与挑战机制构建方面做出了重要贡献。
- **陈文涛** (CAICT): 专注于大型模型的安全性基准测试、评估及标准制定工作。他拥有工业规模评估与基准构建方面的丰富经验。
- **陈杰** (CAICT): 专注于人工智能安全、智能体安全评估及工业测试领域, 拥有评估企业人工智能系统的丰富实践经验。
- **冯伟** (CAICT): 专注于大型语言模型及人工智能代理的安全性及保障方面的评估、基准测试及标准化工作。他为相关研讨会及挑战赛的评估协议设计做出了重要贡献。
- **张兰** (中国科学技术大学, Google Scholar): 中国科学技术大学教授, 研究方向包括移动感知、数据隐私保护及数据共享。她的研究成果已在顶尖移动计算与普适计算领域期刊上发表多篇论文。
- **王志波** (浙江大学, Google Scholar): 浙江大学教授, 专注于智能物联网、人工智能安全、数据安全及隐私保护领域。他在安全系统与大规模部署方面拥有深厚的专业知识。
- **李雪龙** (TeleAI, 中国电信): 担任高级顾问, 负责大规模部署、行业对接及社区推广工作。

这种多元背景的组合对于拟举办的研讨会至关重要。该主题需要具备代理系统、模型安全性、评估协议及实际部署需求等方面知识的专业人士参与。团队完全符合这一要求。

这将是该研讨会的首届活动。其目的并非创建一个通用的人工智能安全平台, 而是旨在打造一个以UbiComp为核心的论坛, 专注于移动、多模态及环境交互场景中值得信赖的代理系统研究。我们期望此次研讨会能帮助业界明确具体任务、优化评估框架, 并制定更实用的术语体系, 用于讨论无处不在智能体的安全性问题。同时, 我们期待该研讨会能够将基准测试开发者、系统设计师及一致性研究者凝聚在一起, 围绕对未来无处不在智能体至关重要的实际问题展开交流。

如果活动取得成功, 该研讨会将有助于推动社区制定长期研究议程。该议程包括建立统一的评估标准、明确智能体交互的安全准则, 以及改进预防措施、监测机制和修复方案之间的比较方法。这些成果与UbiComp研讨会的核心职能高度契合: 既能引发聚焦性讨论, 又能连接通常不在同一场合会面的研究人员, 并协助界定下一阶段的研究课题。我们还期望此次活动能促进移动系统领域与从事智能体安全、模型编辑及可信部署研究的学者之间建立更紧密的合作联系。

近期的研究还持续拓展了网页代理防御、遗忘评估以及多模态编辑基准测试的应用领域[3, 4, 13, 15, 16]。我们期望本次研讨会能够将这些新兴研究方向与移动及无处不在的智能体应用场景有效衔接。

参考文献

- [1] Tri Cao, Bennett Lim, Yue Liu, Yuan Sui, Yuexin Li, Shumin Deng, Lin Lu, Nay Oo, Shuicheng Yan, 与 Bryan Hooi. 2026. VPI- Bench: 面向计算机使用代理的视觉提示注入攻击. arXiv:2506.02456[cs.AI]https://arxiv.org/abs/2506.02456
- [2] Qizhou Chen, Dakan Wang, Taolin Zhang, Zaoming Yan, Chengsong You, Chengyu Wang 和 Xiaofeng He. 2025. UniEdit: 面向大型语言模型的统一知识编辑基准. arXiv:2505.12345[cs. CL]https://arxiv.org/abs/2505.12345
- [3] Yulin Chen, Tri Cao, Haoran Li, Yue Liu, Yibo Li, Yufei He, Le Minh Khoi, Yangqiu Song, Shuicheng Yan, 和 Bryan Hooi. 2026. WebAgent-Guard: 一种基于推理的Web代理提示注入攻击检测防护模型. arXiv:2604.12284[cs. CR]https://arxiv.org/abs/2604.12284
- [4] Vineeth Dorna, Anmol Mekala, Wenlong Zhao, Andrew McCallum, Zachary C. Lipton, J. Zico Kolter 和 Pratyush Maini. 2025. OpenUnlearn: 通过统一方法与指标基准测试加速大语言模型的遗忘机制. arXiv:2506.12618[cs. CL]https://arxiv.org/abs/2506.12618
- [5] Ivan Evtimov, Arman Zharmagambetov, Aaron Grattafiori, Chuan Guo, 和 Kamalika Chaudhuri. 2025. WASP: 针对快速注入攻击的Web代理安全基准测试. arXiv:2504.18575[cs. CR]https://arxiv.org/abs/2504.18575
- [6] Yu He, Haozhe Zhu, Yiming Li, Shuo Shao, Hongwei Yao, Zhihao Liu 和 Zhan Qin. 2026. AttrGuard: 通过工具调用的因果归因击败LLM代理中的间接提示注入. arXiv:2603.10749[cs. CR]https://arxiv.org/abs/2603.10749
- [7] Yicheng Lang, Kehan Guo, Yue Huang, Yujun Zhou, Haomin Zhuang, Tianyu Yang, Yao Su, 和 Xiangliang Zhang. 2025. 超越单一价值指标: 基于认知诊断评估与提升大语言模型的遗忘能力. arXiv:2502.13996[cs. LG]https://arxiv.org/abs/2502.13996
- [8] Hao Li, Ruoyao Wen, Shanghao Shi, Ning Zhang, 和 Chaowei Xiao. 2026. AgentDyn: 一种用于评估现实世界智能体安全系统提示注入攻击的动态开放式基准测试. arXiv:2602.03117[cs. CR]https://arxiv.org/abs/2602.03117
- [9] Zeyi Liao, Lingbo Mo, Chejian Xu, Mintong Kang, Jiawei Zhang, Chaowei Xiao, Yuan Tian, Bo Li 和 Huan Sun. 2025. EIA: 针对通用网络代理的环境注入攻击导致隐私泄露. arXiv:2409.11295[cs. CR]https://arxiv.org/abs/2409.11295
- [10] Yinuo Liu, Ruohan Xu, Xilong Wang, Yuqi Jia 和 Neil Zhenqiang Gong. 2025. WAIInjectBench: Web代理即时注入检测的基准测试. arXiv:2510.01354[cs.citation]https://arxiv.org/abs/2510.01354
- [11] Narek Maloyan 与 Dmitry Namiot. 2026. 《协议漏洞解析: 工具集成式大语言模型代理中模型上下文协议规范与提示注入漏洞的安全性分析》. arXiv:2601.17549[cs. CR]https://arxiv.org/abs/2601.17549
- [12] Haewon Park, Gyubin Choi, Minjun Kim, 和 Yohan Jo. 2025. 面向语言模型的上下文鲁棒知识编辑. arXiv:2505.23026[cs. CL]https://arxiv.org/abs/2505.23026
- [13] Ruichen Qiu, Jiajun Tan, Jiayue Pu, Honglin Wang, Xiao-Shan Gao 和 Fei Sun. 2025. 大型语言模型中的遗忘现象综述. arXiv:2510.25117[cs. CL]https://arxiv.org/abs/2510.25117
- [14] Anil Ramakrishna, Yixin Wan, Xiaomeng Jin, Kai-Wei Chang, Zhiqi Bu, Bhanukiran Vinzamuri, Volkan Cevher, Mingyi Hong 和 Rahul Gupta. 2025. SemEval-2025 任务4: 从大型语言模型中移除敏感内容. arXiv:2504.02883[cs. CL]https://arxiv.org/abs/2504.02883
- [15] 此外, Deep Singh, Maximilian Muller, Francesco Croce 和 Matthias Hein. 2025. 《持久性遗忘: 大语言模型中保留效用、稳健且近乎不可逆的遗忘机制》. arXiv:2509.02820[cs. LG]https://arxiv.org/abs/2509.02820
- [16] Dexuan Xu, Jieyi Wang, Zhongyan Chai, Yongzhi Cao, Hanpin Wang, Huamin Zhang 和 Yu Huang. 2025. MedMKEB: 面向医学多模态大型语言模型的综合性知识编辑基准. arXiv:2508.05083[cs.AI]https://arxiv.org/abs/2508.05083
- [17] Yifan Xu, Xiao Liu, Xueqiao Sun, Siyi Cheng, Hao Yu, Hanyu Lai, Shudan Zhang, Dan Zhang, Jie Tang, 和 Yuxiao Dong. 2024. AndroidLab: Android 自主智能体的训练与系统性基准测试. arXiv:2410.24024[cs. AI]https://arxiv.org/abs/2410.24024
- [18] Chenlong Yin, Runkeng Geng, Yanting Wang, 和 Jinyuan Jia. 2026. PISmith: 基于强化学习的提示注入防御红队测试方法. arXiv:2603.13026[cs. LG]https://arxiv.org/abs/2603.13026

- [19] Hanrong Zhang 、 Jingyuan Huang 、 Kai Mei 、 Yifei Yao 、 Zhenting Wang 、 Chenlu Zhan 、 Hongwei Wang 和 Yongfeng Zhang 。2025。智能体安全基准（ASB）：基于大语言模型智能体的攻击与防御方法的规范化与基准测试。arXiv:2410.02644[cs. CR]<https://arxiv.org/abs/2410.02644>

A 附录：基于文本的CFP

研讨会标题：迈向普适计算中的可信代理式人工智能：首届关于动态评估、执行安全与精度对齐的研讨会暨挑战赛

概述。本次研讨会探讨如何在普适计算环境中构建、评估并改进可信的人工智能代理。我们重点关注能够与应用程序、设备、服务及物理环境交互的移动型、多模态及工具使用型代理。研讨会内容涵盖论文展示、海报报告以及围绕三大主题的挑战赛项目：动态攻击、执行安全性与精确对齐。

研究重点。主要研究主题包括：针对人工智能代理的攻击、提示注入、工具使用不安全问题、MCP安全性、执行轨迹追踪、轨迹检查、移动及可穿戴助手的安全规划、多模态与环境基础评估、模型编辑、选择性遗忘、安全性与效用之间的权衡关系，以及可信代理系统的基准测试。

目标受众与适用范围。本次研讨会面向来自普适计算、移动系统、人工智能安全、网络安全、多模态学习及基准测试领域的研究人员与实践者。我们欢迎针对这两种方法及其评估的研究工作，尤其是那些在真实交互循环（而非仅限静态场景）中研究智能体的研究。

提交类型。

- 2-4页的档案工作坊论文；
- 1 页非档案类参与声明或海报。

审稿流程。所提交的稿件将经过初步评审；入选的作品将受邀进行口头专题展示，其余被接受的作品将以海报形式展出。

工作坊形式。该活动计划包括特邀报告、简短论文报告、海报展示环节及讨论环节。

本次会议围绕三大挑战方向展开。讨论环节将重点探讨评估设计、安全交互协议以及智能体故障的精准修复方法。

开放式研讨会政策。本次研讨会定为开放式线下活动。UbiComp/ ISWC 参会者无需提交论文即可参加，但须完成注册并符合会议室容量限制。

挑战赛道。

- 曲目 1：特工与 MCP 的袭击。
- 轨道2：执行安全。
- 轨道3：精确对齐。

挑战参与。我们计划在研讨会网站上发布任务描述、评估规则及入门材料。参与者可通过提交论文或以仅限挑战组的形式参与本次挑战，具体事宜以网站最终政策及活动安排为准。

暂定时间表。

- 2026年5月5日：研讨会网站及CFP文件发布；
- 2026年6月下旬：提交截止日期；
- 2026年7月中旬：接受通知；
- 2026年7月31日：最终材料提交截止日期；
- 2026年10月11日或12日：在上海举行的UbiComp/ ISWC 2026大会上举办研讨会。

预期成果。我们希望本次研讨会能够有助于明确评估目标、改进报告实践，并促进在普适计算领域为可信代理系统共享资源。

组织者：赵健（TeleAI，中国电信；西北 polytechnic 大学）、张天乐（TeleAI，中国电信）、周慧林（中国科学技术大学；TeleAI）、陈文涛（CAICT）、陈杰（CAICT）、魏峰（CAICT）、张兰（中国科学技术大学）、王志波（浙江大学）和李雪龙（TeleAI，中国电信）。